UNIVERZITET U NOVOM SADU

PRIRODNO-MATEMATIČKI FAKULTET

DEPARTMAN ZA MATEMATIKU I INFORMATIKU

SEMINARSKI RAD IZ SOFTVERSKOG INŽENJERSTVA ZA SISTEME BAZA PODATAKA

Mira Gospavić 382/21 IT

prof. dr Jovana Vidaković

Sadržaj:

1. Uvod 2
2. Opis OLTP baze podataka i izvora podataka 2
3. Opis OLAP baze podataka 6
4. Opis ECTL procesa 7
5. Upiti za izvještaje 12
5.1. Koji hoteli ostvaruju najveći prihod 12
5.2. Koja vrsta sobe donosi najvise prihoda po godini 12
5.3. Koliko noćenja biraju gosti iz različitih zemalja 13
5.4. Najčešći posjetioci 13
5.5. Prihodi zaposlenog u poređenju sa brojem ostvarenih rezervacija 14
5.6. Analiza rezervacija soba po mjesecu 14
5.7. Kako ocjene gostiju utiču na popujenost hotela? 15
5.8. Ukupna zarada za sve hotele koji su ostvarili rezervaciju u 2022. 16
6. Zaključak 17

1. Uvod

Glavna motivacija za izradu ovog projekta je potreba za efikasnim upravljanjem velikim količinama podataka koje generiše hotelski sistem. Cilj projekta jeste da se, iz postojećeg OLTP sistema hotela, izgradi OLAP skladište podataka koje će omogućiti bolje donošenje poslovnih odluka.

Hotelski menadžment generiše velike količine podataka kroz rezervacije, goste, sobe, plaćanja i recenzije. Podaci su često nepovezani, zbog toga je potrebno kreirati centralizovano skladište podataka (data warehouse) koje omogućava lako i brzo izvršavanje analitičkih upita. U ovom projektu se radi modelovanje OLTP baze, definisanje poslovnih procesa, prepoznavanje ključnih pitanja na koje treba odgovoriti, izgradnja OLAP baze i generisanje upita koji daju odgovor na definisana pitanja.

2. Opis OLTP baze podataka i izvora podataka

OLTP baza projekta predstavlja hotelski sistem i čini glavni izvor podataka, na osnovu kog se gradi OLAP struktura (slika 1.).

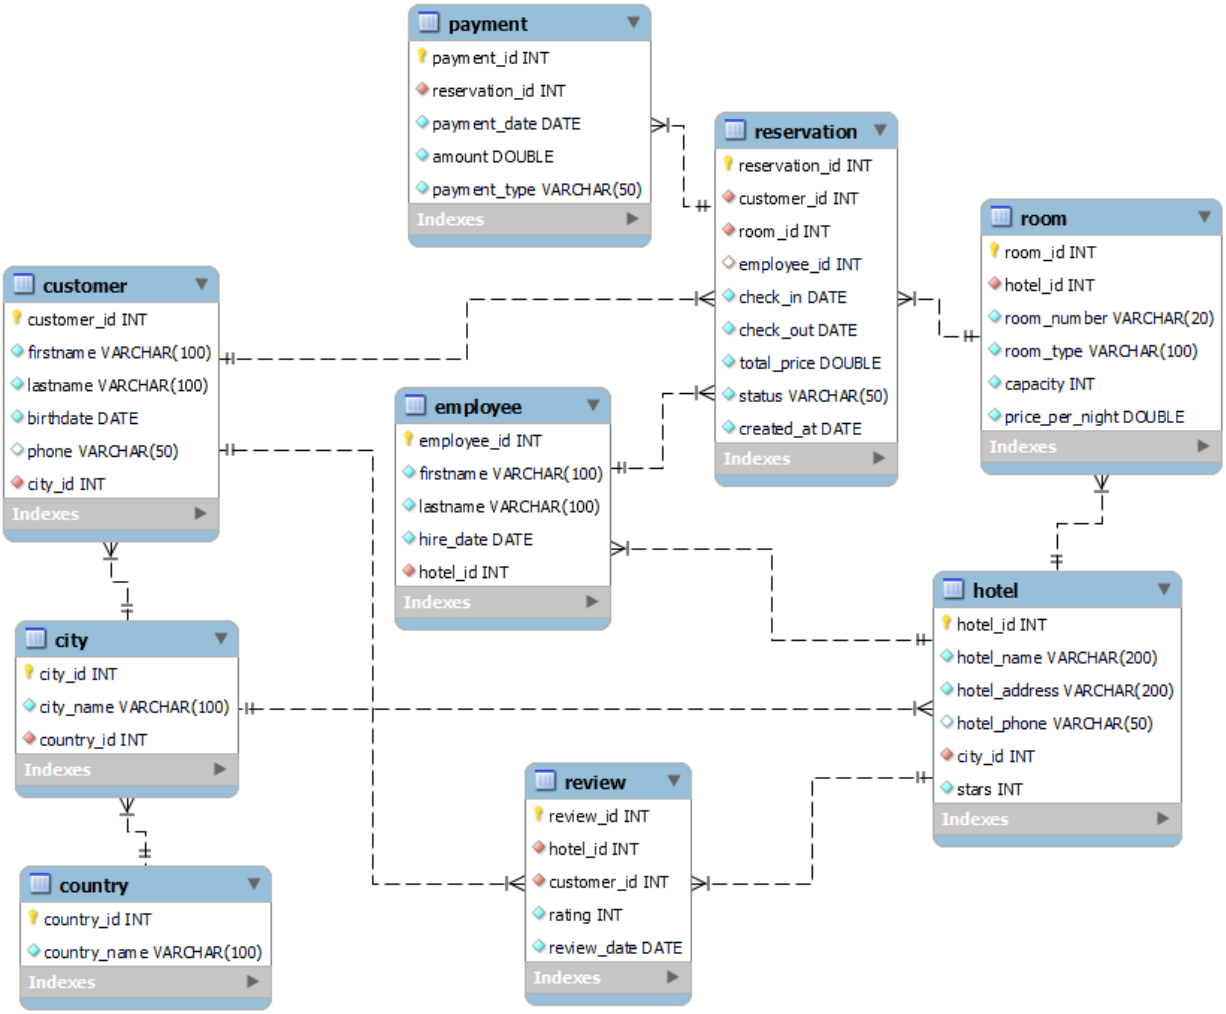

Slika 1.

Podaci tabela su popunjavani iz različitih izvora. Tabele *country* i *city* su popunjene stvarnim podacima, dataset-ovima sa sajta kaggle (kaggle countries, kaggle largest cities).

Podaci za tabelu *room* su generisani pomoću python skripte, kako bi što bolje simulirali moguće stvarne podatke (slika 2.1.).

```python
num_rooms = 1000

room_types = ['single', 'double', 'twin', 'suite', 'family', 'triple']
capacities = {
'single': 1,
'double': 2,
'twin': 2,
'triple': 3,
'family': 4
}
prices = {
'single': (11, 40),
'double': (11, 60),
'twin': (11, 40),
'triple': (20, 60),
'family': (18, 79),
'suite': (50, 300)
}

with open('C:\\Users\\USER\\Downloads\\sobe3001.csv', 'w', newline='') as csvfile:
    writer = csv.writer(csvfile)
    writer.writerow(['room_id', 'room_number', 'room_type', 'capacity', 'hotel_id', 'price_per_night'])


    for i in range(num_rooms):
        room_id = 3001 + i
        room_number = random.randint(1, 600)
        room_type = random.choice(room_types)

        if room_type == 'suite':
            capacity = random.choices([4,5,6], weights=[4,4,2])[0]
        else:
            capacity = capacities[room_type]

        hotel_id = random.randint(1, 2000)
        price_min, price_max = prices[room_type]
        price_per_night = round(random.uniform(price_min, price_max))/1.00

        writer.writerow([room_id, room_number, room_type, capacity, hotel_id, price_per_night])
```

Slika 2.1.

Tabele *hotel, customer, reservation* i *employee* su generisane preko mockaroo sajta, uz naknadno filtriranje i povezivanje *reservation* csv fajlova, tako da budu u skladu sa postojećim hotelima i sobama.

Za popunjavanje tabela *payment* i *review* su takođe korišćene python skripte, u skladu sa podacima u *reservation*, odnosno *reservation* i *room* tabelama; npr. *payment* se kreira samo za resezervaciju čiji je status *completed* za određenog posjetioca (slika 2.2. i 2.3.).

```python
reservations = pd.read_csv(r"C:\Users\USER\Downloads\MOCK_DATA (22).csv")
rooms = pd.read_csv(r"C:\Users\USER\Downloads\sobe3001.csv")

reservations.columns = reservations.columns.str.strip()
rooms.columns = rooms.columns.str.strip()

reservations = reservations[pd.to_numeric(reservations['room_id'], errors='coerce').notnull()]
reservations['room_id'] = reservations['room_id'].astype(int)

rooms['room_id'] = rooms['room_id'].astype(int)
rooms['price_per_night'] = rooms['price_per_night'].astype(float)

def random_checkout(check_in_str):
    check_in_date = datetime.strptime(check_in_str, "%Y-%m-%d")
    return (check_in_date + timedelta(days=random.randint(1, 15))).strftime("%Y-%m-%d")

def random_created_at(check_in_str):
    check_in_date = datetime.strptime(check_in_str, "%Y-%m-%d")
    return (check_in_date - timedelta(days=random.randint(2, 60))).strftime("%Y-%m-%d")

def calculate_total_price(row):
    check_in_date = datetime.strptime(row['check_in'], "%Y-%m-%d")
    check_out_date = datetime.strptime(row['check_out'], "%Y-%m-%d")
    nights = (check_out_date - check_in_date).days

    room_row = rooms[rooms['room_id'] == row['room_id']]

    if room_row.empty:
        print(f" room_id {row['room_id']} ne postoji u rooms.csv")
        return 0.0

    price_per_night = room_row.iloc[0]['price_per_night']
    return round(price_per_night * nights, 2)
```

Slika 2.2.

```python
REFERENCE_DATE = datetime.strptime("2025-01-01", "%Y-%m-%d")

def fix_status(row):
    check_in_date = datetime.strptime(row['check_in'], "%Y-%m-%d")
    check_out_date = datetime.strptime(row['check_out'], "%Y-%m-%d")
    status = row['status'].strip().lower()

    if check_in_date < REFERENCE_DATE:

        if status == "booked":
            return random.choice(["cancelled", "completed"])
        if status in ["completed", "cancelled"]:
            return status
        return status
    elif check_in_date > REFERENCE_DATE:
        return status

    elif check_out_date < REFERENCE_DATE:
        if status== "booked":
            return random.choice(["cancelled", "completed"])
        if status in ["completed", "cancelled"]:
            return status
        return status
    else:
        return status

reservations['status'] = reservations.apply(fix_status, axis=1)
reservations['check_out'] = reservations['check_in'].apply(random_checkout)
reservations['created_at'] = reservations['check_in'].apply(random_created_at)
reservations['total_price'] = reservations.apply(calculate_total_price, axis=1)

reservations.to_csv(r"C:\Users\USER\Downloads\reservations3001.csv", index=False)
```

Slika 2.3.

Neka relevantna pitanja na koja olap baza treba pružiti odgovor:

1. Koji hoteli ostvaruju najveći prihod?
2. Koja vrsta sobe je najprofitabilnija po godinama?
3. Koji gosti najčešće dolaze?
4. Kakav je odnos zarade koju donosi zaposleni i broja ostvarenih rezervacija?
5. Da li lošije ocjene utiču na smanjenje popunjenosti hotela?

3. Opis OLAP baze podataka

OLAP baza podataka se zasniva na star schema modelu. Sadrži dvije tabele činjenica, *dw_fact_reservation* i *dw_fact_review,* i dimenzije *dw_dim_country, dw_dim_city, dw_dim_time, dw_dim_customer, dw_dim_hotel, dw_dim_room, dw_dim_employee* i *dw_dim_payment_type* (slika 3.). Tabela *dw_fact_review* pruža odgovore na pitanja vezana za ocjene korisnika, pa je u skladu sa tim direktno povezana sa dimenzijama *time*, *customer* i *hotel*, dok tabela *dw_fact_reservation* obuhvata veći skup pitanja vezanih za rezervacije te je povezana i sa *room*, *empoyee* i *payment_type* dimenzijama.

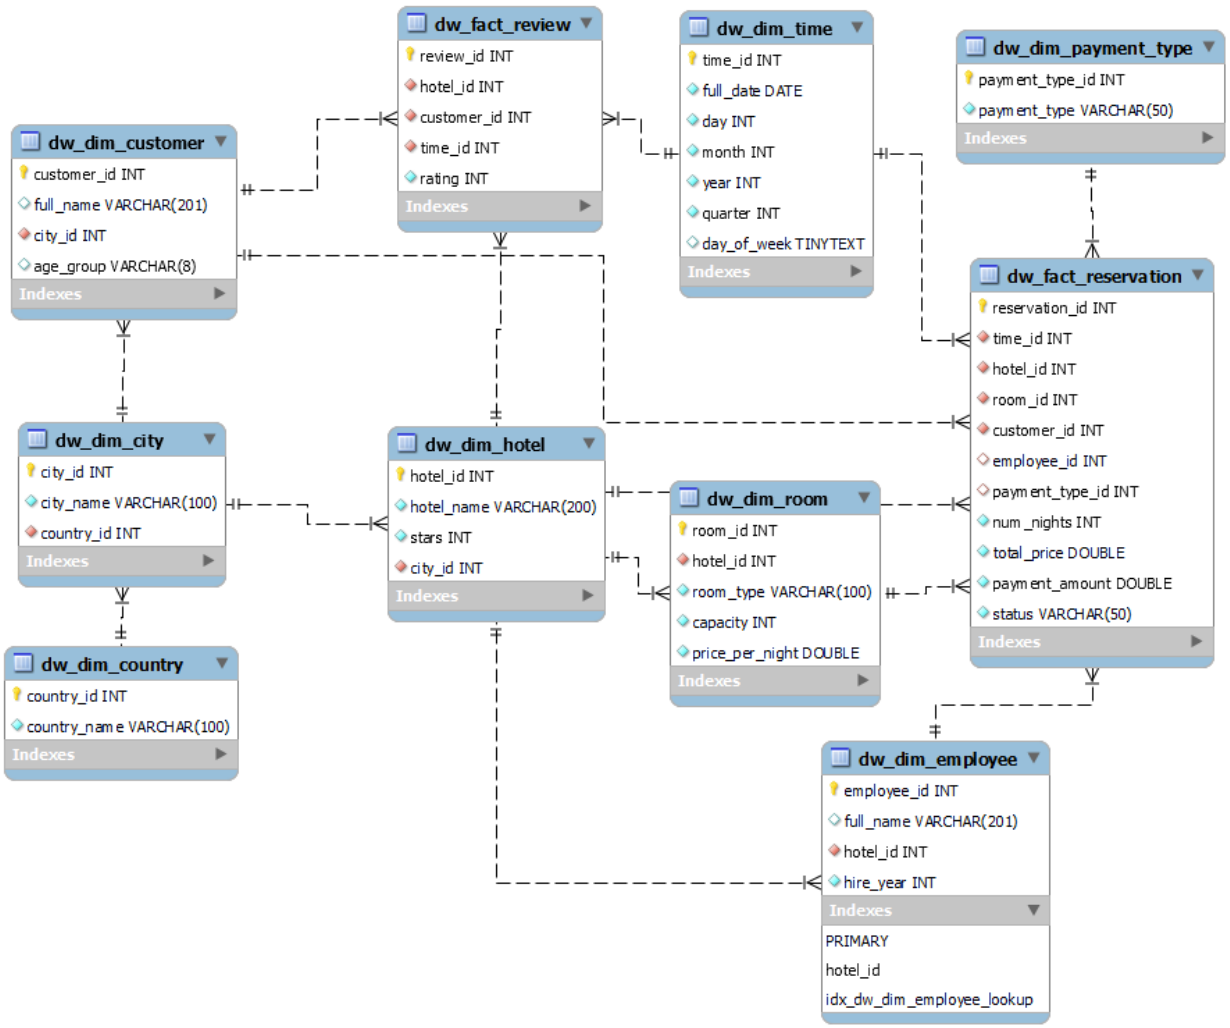

Slika 3.

4. Opis ECTL procesa

Za transformacije podataka iz OLTP baze korišćen je alat Spoon iz paketa *Pentaho Data Integration.*

Za jednostavnije tabele, gdje nema ponavljanja uslijed izvora podataka, *country* i *city*, korišćen je *table input* sa prostim sql upitom, u kombinaciji sa *insert/update* (slika 4.1. i 4.2.).

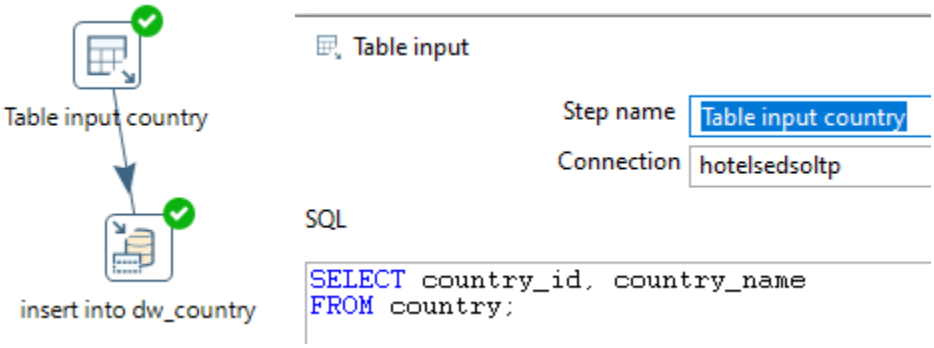

Slike 4.1. i 4.2.

Za tabelu *dw_dim_hotel*, koristi se kombinacija koraka kako bi se izbjegli hoteli sa istim imenom u istom gradu, u tom slučaju uzimamo *hotel_id* prvog, a polje *stars* je aritmetička sredina zaokružena na cijeli broj ka dole (slike 5.1. i 5.2.).

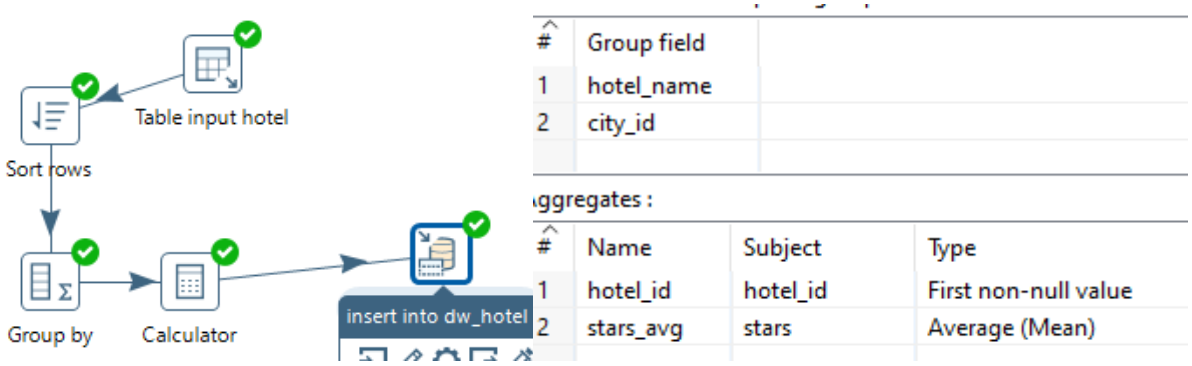

Slike 5.1. i 5.2.

Za tabelu *dw_dim_room*, potrebno je provjeriti da li se *hotel_id* nalazi u prečišćenoj olap *dw_dim_hotel* tabeli, zatim se redovi koji nisu *null* šalju u naredni korak, a kod duplih brojeva soba u istim hotelima bira se prva soba (slika 6.). U olap bazu je nakon transformacije ubačeno 2610 od originalnih 4000 redova.

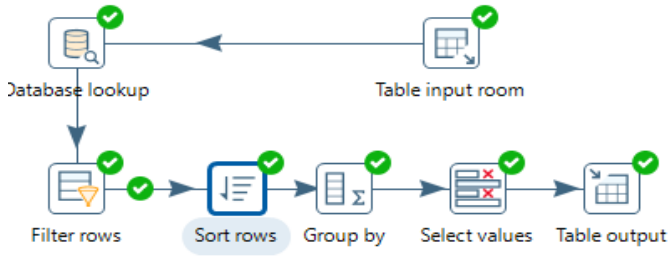

Slika 6.

Tabela *dw_dim_employee* se popunjava na sličan način (slika 7.), na kraju se preko *calculator* izračuna *hire_year* od *hire_date* polja. U olap bazu se unose samo validni zaposleni, tako da ako postoji više redova sa istim *hotel_id, employee_name* i *hire_date*, upisujemo samo jednog.

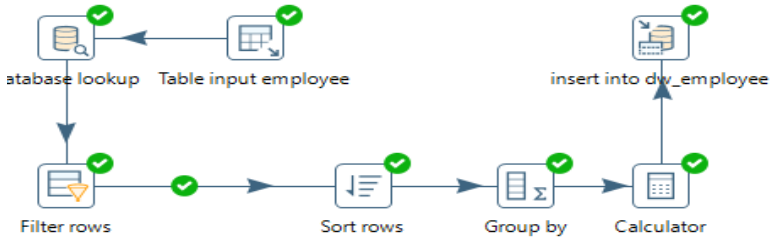

Slika 7.

Dw_dim_customer tabela je popunjena sa *table input* i *insert/update*, uz sql upit za definisanje polja *full_name* i *age_group* (slika 8.); alternativno mogle su se koristiti i druge metode za kreiranje polja, na primjer *modified javascript value.*

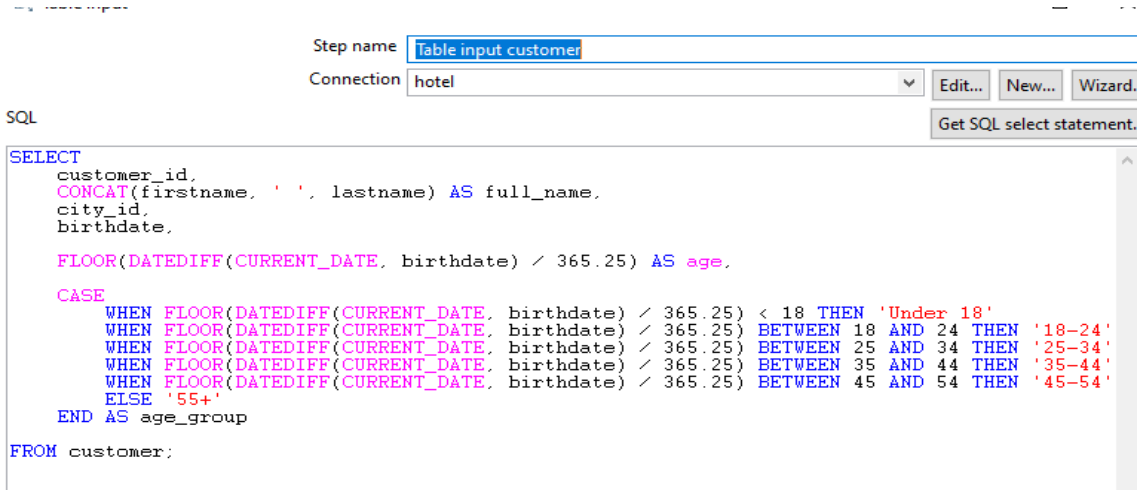

Slika 8.

Za tabelu *dw_payment_type* se koristi *table input* i *insert/update*, uz dodatni korak *add sequence* za dodavanje *payment_type_id*, koje ne postoji kao referento polje u oltp tabeli (slika 9.1. i 9.2).

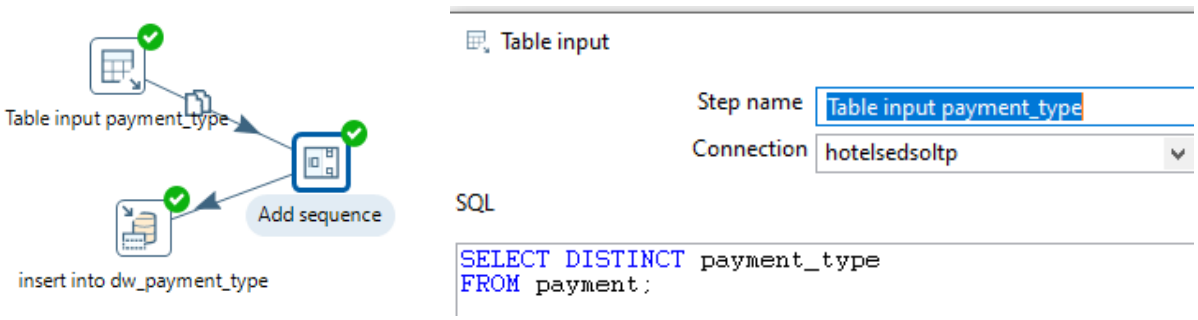

Slike 9.1. i 9.2.

Dimenzija *dw_dim_time* se popunjava generisanjem oko 4000 redova, datumi od 2020-01-01 do 2030-12-31, uz propratna polja, *day, day_of_week, month, year* i *quarter*, uz to da se polje *quarter* generiše na osnovu *month* kroz *modified js value*. Dodatno, preko *add sequence* pravi se polje *time_id* i podaci se unose u tabelu (slika 10.).

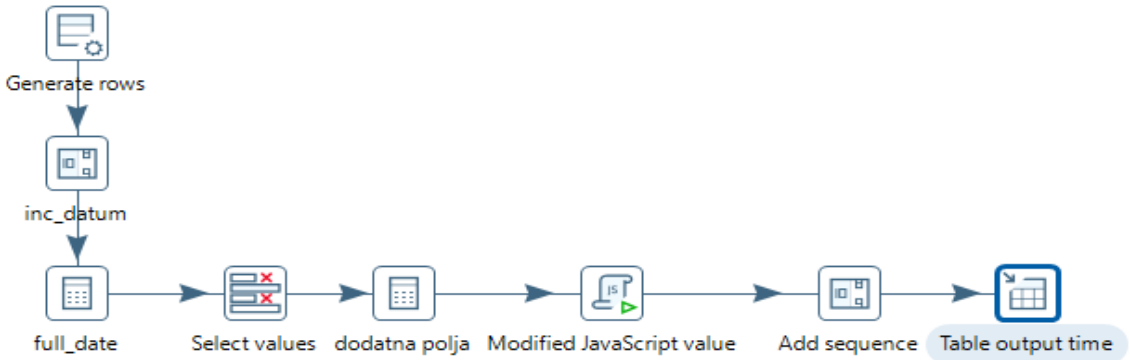

Slika 10.

Tabela činjenica, *dw_fact_reservation*, popunjava se podacima iz *reservation*, *room* i *payment*, tabele se sortiraju i spajaju (*merge*) (slika 11.1.). Nakon prolaska kroz *database lookup payment*, kroz *calculator* se dodaje polje *payment_amount* koje uzima vrijednost *total_price* i kao takvo se transformiše preko *modified js value*, tako da iznosi 0 za one rezervacije čiji status nije *completed* (slika 11.2.).

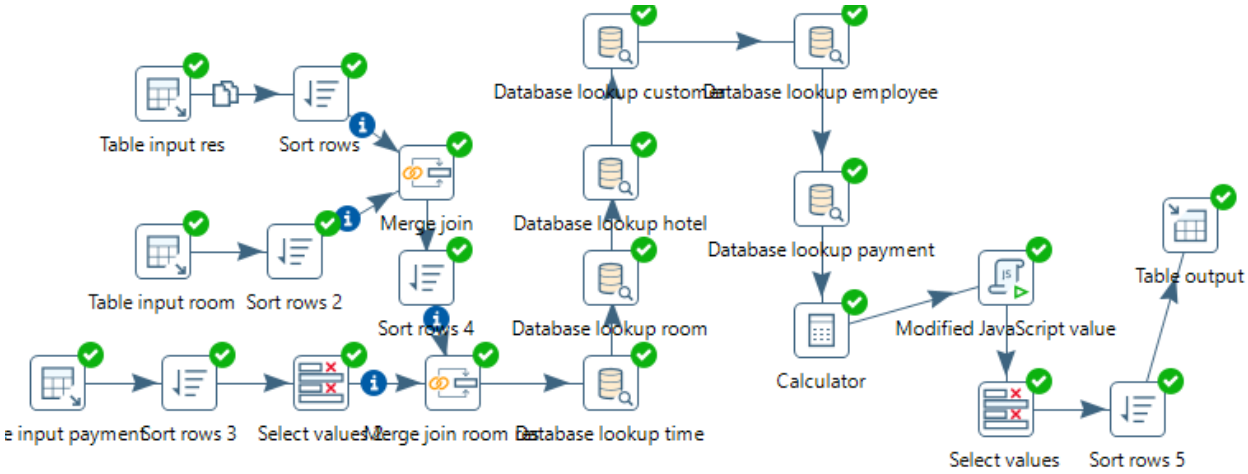

Slika 11.1.

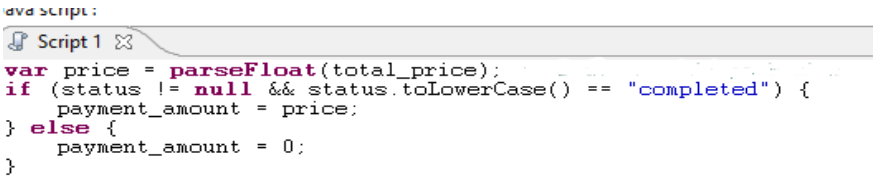

```
var price = parseFloat(total_price);
if (status != null && status.toLowerCase() == "completed") {
    payment_amount = price;
} else {
    payment_amount = 0;
}
```

Slika 11.2.

Na slici 11.3. vidi se isječak podataka ubačenih u tabelu *dw_fact_reservation* nakon transformacije.

reservation_id	time_id	hotel_id	room_id	customer_id	employee_id	payment_type_id	num_nights	total_price	payment_amount	status
347	525	1005	127	563	733	1	14	224	224	completed
348	1562	1886	294	787	843	1	2	64	0	cancelled
351	1375	1110	323	2940	2320	1	4	372	372	completed
354	1829	986	486	930	421	1	14	308	0	booked
355	1489	1249	330	2638	839	1	3	117	0	cancelled

Slika 11.3.

Dw_fact_review tabela je popunjena podacima iz *review* i *hotel,* nakon sortiranja podaci se spajaju i prolaze kroz odgovarajuće *database lookup* kako bi ih uskladili sa postojećim podacima (slika 12.1.). Na slici 12.2. vidi se dio podataka ubačenih u tabelu nakon transformacije.

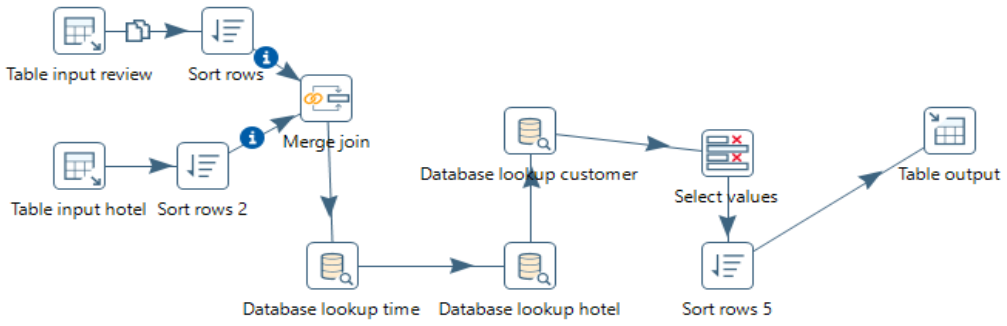

Slika 12.1.

review_id	hotel_id	customer_id	time_id	rating
1	1988	1758	1291	4
2	190	3585	571	1
3	638	3638	960	4
5	206	2445	1762	4
6	1726	657	430	4
7	110	132	880	2
8	1726	2508	997	5
9	1221	140	1575	4
12	796	3569	520	4
13	110	1260	2203	5
15	1311	1851	2099	1

Slika 12.2.

5. Upiti za izvještaje

5.1. Koji hoteli ostvaruju najveći prihod, upit sa dijelom dobijenih rezultata prikazani su na slikama 13.1. i 13.2.

```
SELECT h.hotel_name, cn.country_name,
       SUM(f.total_price) AS total_revenue
FROM dw_fact_reservation f
JOIN dw_dim_hotel h ON f.hotel_id = h.hotel_id
JOIN  dw_dim_city c ON h.city_id = c.city_id
JOIN dw_dim_country cn ON c.country_id = cn.country_id
GROUP BY h.hotel_name, cn.country_name
ORDER BY total_revenue DESC;
```

hotel_name	country_name	total_revenue
Span	China	11478
Overhold	Turkey	9814
Sonair	China	8036
Mat Lam Tam	China	7522
Stronghold	China	6725.2
Flowdesk	China	6560
Y-find	Pakistan	6524
Wrapsafe	China	6473
Andalax	Bangladesh	6380
Konklux	China	6177
Stringtough	China	5733
Matsoft	China	5604.4
Vagram	China	5556
Konklab	China	5184

Slika 13.1. i 13.2.

5.2. Koja vrsta sobe donosi najviše prihoda po godini, upit je prikazan na slici 14.1, a dobijeni rezultat na slici 14.2.

```
SELECT r.room_type, t.year,
       SUM(f.payment_amount) AS revenue
FROM dw_fact_reservation f
JOIN dw_dim_room r ON f.room_id = r.room_id
JOIN dw_dim_time t ON f.time_id = t.time_id
GROUP BY t.year, r.room_type
ORDER BY t.year ASC, revenue DESC;
```

room_type	year	revenue
suite	2021	4689
family	2021	4173
triple	2021	2799
single	2021	1800
double	2021	1359
twin	2021	1248
suite	2022	8148
double	2022	5123
family	2022	4825
single	2022	1329
twin	2022	1292
triple	2022	594
suite	2023	59834.6
family	2023	15576

Slika 14.1. i 14.2.

5.3. Koliko noćenja biraju gosti iz različitih zemalja, upit i dio rezultata prikazani su na slikama 15.1. i 15.2.

```
SELECT ctry.country_name,
       SUM(f.num_nights) AS total_nights
FROM dw_fact_reservation f
JOIN dw_dim_customer cust ON f.customer_id = cust.customer_id
JOIN dw_dim_city city ON cust.city_id = city.city_id
JOIN dw_dim_country ctry ON city.country_id = ctry.country_id
GROUP BY ctry.country_name
ORDER BY total_nights DESC;
```

country_name	total_nights
China	3945
India	1584
Brazil	421
Indonesia	392
Mexico	392
Nigeria	329
Pakistan	314
United States	256
Japan	253
Iran	221
Italy	210
South Africa	209
Canada	198
Bangladesh	192
Russia	192

Slika 15.1. i 15.2.

5.4. Najčešći posjetioci, upit je prikazan na slici 16.1, a dio dobijenih rezultata na slikama 16.2. i 16.3.

```sql
select
    c.customer_id,
    c.full_name,
    count(*) as total_res,
    CASE
        WHEN COUNT(*) > 1 THEN 'ponovni gost'
        ELSE 'jedna posjeta'
    END AS guest_type
FROM dw_fact_reservation f
JOIN dw_dim_customer c ON f.customer_id = c.customer_id
GROUP BY c.customer_id, c.full_name
ORDER BY total_res DESC limit 1500;
```

Slika 16.1.

customer_id	full_name	total_res	guest_type
229	Arabel Cavilla	4	ponovni gost
3173	Grange Wonham	4	ponovni gost
92	Janette Sayward	3	ponovni gost
120	Murielle Brazelton	3	ponovni gost
321	Wallache Middlebrook	3	ponovni gost
361	Clark Righy	3	ponovni gost
378	Rupert Itzik	3	ponovni gost
393	Paulina Lawdham	3	ponovni gost
575	Roze Glentz	3	ponovni gost
577	Claretta Dummett	3	ponovni gost
873	Aveline Heggison	3	ponovni gost
884	Sukey Lavall	3	ponovni gost

customer_id	full_name	total_res	guest_type
3868	Cordelie Bowmer	2	ponovni gost
3886	Kial Board	2	ponovni gost
3889	Louie Beachem	2	ponovni gost
3932	Agnola Traynor	2	ponovni gost
3978	Stephine Rubert	2	ponovni gost
6	Nadiya Roostan	1	jedna posjeta
7	Maison Godbold	1	jedna posjeta
9	Eimile Lidington	1	jedna posjeta
11	Danni Stevenson	1	jedna posjeta

Slika 16.2. i 16.3.

5.5. Prihodi zaposlenog u poređenju sa brojem ostvarenih rezervacija, upit i dio rezultata prikazani su na slikama 17.1. i 17.2.

```sql
SELECT
    e.full_name AS employee,
    COUNT(*) AS completed_res,
    SUM(f.total_price) AS total_revenue
FROM dw_fact_reservation f
JOIN dw_dim_employee e ON f.employee_id = e.employee_id
where f.status = "completed"
GROUP BY f.employee_id
ORDER BY total_revenue DESC;
```

employee	completed_res	total_revenue
Leanora Kissick	2	5915
Lynda Ronchka	3	5239
Gal Cuniam	3	5087
Gilburt Brettoner	2	4800
Prudi McSweeney	1	3915
Lion Baume	3	3516
Shanta Flohard	2	3396
Budd Skelhorn	1	3245
Morly Beahan	1	3237
Teresina Ducker	1	3080
Adaline Allum	1	2850
Georgie Spiring	1	2756
Lee Dunbleton	1	2720
Jeanne Douglass	1	2640

Slika 17.1. i 17.2.

5.6. Analiza rezervacija soba po mjesecu, na slikama 18.1. i 18.2. prikazani su upit i dio dobijenih rezultata.

```sql
WITH monthly_counts AS (
    SELECT
        t.year,
        t.month,
        r.room_type,
        COUNT(*) AS num_reservations
    FROM dw_fact_reservation f
    JOIN dw_dim_time t ON f.time_id = t.time_id
    JOIN dw_dim_room r ON f.room_id = r.room_id
    GROUP BY t.year, t.month, r.room_type
),
ranked AS (
    SELECT
        year,
        month,
        room_type,
        num_reservations,
        ROW_NUMBER() OVER (PARTITION BY year, month ORDER BY num_reservations DESC) AS rn
    FROM monthly_counts
)
SELECT
    year,
    month,
    room_type,
    num_reservations AS total_reservations
FROM ranked
```

Slika 18.1

year	month	room_type	total_reservations
2021	1	single	3
2021	2	single	2
2021	3	twin	4
2021	4	family	5
2021	5	twin	2
2021	6	family	3
2021	7	family	6
2021	8	family	2
2021	9	single	4
2021	10	suite	2
2021	11	twin	2
2021	12	twin	2
2022	1	double	4
2022	2	suite	2

year	month	room_type	total_reservations
2022	3	triple	2
2022	4	double	2
2022	5	twin	3
2022	6	double	2
2022	7	double	3
2022	8	twin	2
2022	9	double	2
2022	10	twin	2
2022	11	double	3
2022	12	family	4
2023	1	double	11
2023	2	twin	7
2023	3	single	13
2023	4	twin	10

Slika 18.2. i 18.3.

5.7. Kako ocjene gostiju utiču na popujenost hotela? Upit i dio rezultata prikazani su na slikama 19.1. i 19.2.

```sql
SELECT
    h.hotel_id, h.hotel_name,
    AVG(r.rating) AS avg_rating,
    COUNT(DISTINCT r.customer_id) AS total_reservations
FROM dw_fact_review r
JOIN dw_dim_hotel h
    ON r.hotel_id = h.hotel_id
LEFT JOIN dw_fact_reservation f
    ON f.hotel_id = h.hotel_id
GROUP BY h.hotel_id
ORDER BY total_reservations DESC, avg_rating DESC;
```

hotel_id	hotel_name	avg_rating	total_reservations
110	Greenlam	2.4000	5
223	Zamit	4.5000	4
440	Regrant	3.0000	4
1726	Domainer	3.0000	4
659	Andalax	2.7500	4
245	Bitchip	2.5000	4
691	Holdlamis	4.6667	3
429	It	4.0000	3
1023	Aerified	3.6667	3
861	Tempsoft	3.3333	3
174	Gembucket	3.0000	3
938	Toughjoyfax	3.0000	3
138	Flowdesk	2.6667	3
677	Tampflex	2.6667	3

Slika 19.1. i 19.2.

5.8. Ukupna zarada za sve hotele koji su ostvarili rezervaciju u 2022. Na slikama 20.1. i 20.2. prikazani su upit i dio rezultata upita.

```sql
select h.hotel_name, c.city_name, r.num_nights, r.payment_amount
from dw_fact_reservation r
join dw_dim_hotel h
    on r.hotel_id = h.hotel_id
join dw_dim_city c on
    h.city_id = c.city_id
join dw_dim_time t on
    r.time_id = t.time_id
where r.status = "completed" and t.year = 2022
order by r.num_nights desc;
```

Slika 20.1.

hotel_name	city_name	num_nights	payment_amount
Sub-Ex	Manila	15	360
Fintone	Dhaka	14	826
Tampflex	Mexico City	14	406
Voltsillam	Delhi	14	336
Sonsing	Tianjin	13	585
Wrapsafe	Shanghai	13	338
Opela	Chongqing	13	1807
Tampflex	Beijing	13	247
Sub-Ex	Dhaka	12	144
Veribet	Rio De Janeiro	12	912
Domainer	Sao Paulo	12	348
Stringtough	Shanghai	11	1650
Fixflex	Dhaka	11	451
Sonair	Lagos	11	396
Redhold	Delhi	11	264

Slika 20.2.

6. Zaključak

Projekat demonstrira kako se iz klasičnog OLTP sistema može efikasno kreirati OLAP skladište podataka. Dobijeni modeli, transformacije i upiti za izvještaje omogućavaju hotelima da bolje razumiju svoje poslovanje, identifikuju obrasce ponašanja gostiju i optimizuju resurse. Rezultati ukazuju na vrijednost *data warehouse* pristupa u modernom hotelskom menadžmentu.